

一阶优化方法

MODULE B1

Méthodes d'optimisation du premier ordre

Sauf mention contraire, \mathcal{X} (resp. \mathcal{Y}) est un espace de HILBERT, muni du produit scalaire noté $\langle \cdot, \cdot \rangle$ et on note $\|\cdot\|$ la norme qui découle du produit scalaire.

L'objectif de ce module est de poser les bases théoriques des méthodes d'optimisation du premier ordre, avec en particulier la règle de FERMAT, ainsi que de présenter les enjeux et les problématiques rencontrés en optimisation numérique. 挑战

遇到的问题

1 Problèmes d'optimisation 优化问题

1.1 Définitions 定义

Résoudre un problème d'optimisation, c'est chercher à minimiser ou à maximiser une fonction dite *objectif*.

Définition 1 (Minimiseurs et minimum) 最小值点和最小值

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction et $x^* \in \mathcal{X}$ tel que $J(x^*) \in \mathbb{R}$. On dit que x^* est un *minimiseur (global)* de J si

$$\forall x \in \mathcal{X}, \quad J(x^*) \leq J(x)$$

L'ensemble des *minimiseurs (globaux)* de J (éventuellement vide) est noté

$$\operatorname{argmin}_{x \in \mathcal{X}} J(x) \subset \mathcal{X}$$

Dans ce cas, la *valeur réelle* $J(x^*)$ est appelée *minimum (global)* de J , notée

$$\min_{x \in \mathcal{X}} J(x) \in \mathbb{R}$$

REMARQUE : Dans la définition précédente, il est inutile de considérer les fonctions pouvant prendre la valeur $-\infty$ car celles-ci ne peuvent admettre de *minimiseur* ni de *minimum*.

On précise parfois *minimiseur / minimum global* pour les distinguer de leur homologue local :

Définition 2 (Minimiseurs locaux) 局部最小值点

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty, -\infty\}$ une fonction et $x^* \in \mathcal{X}$ tel que $J(x^*) \in \mathbb{R}$. On dit que x^* est un *minimiseur local* de J s'il existe un *voisinage* $\mathcal{V}(x^*) \subset \mathcal{X}$ tel que

$$\forall x \in \mathcal{V}(x^*), \quad J(x^*) \leq J(x)$$

Dans ce cas, la *valeur réelle* $J(x^*)$ est appelée *minimum local* de J .

Notons que, si le **minimum global** (lorsqu'il existe) d'une fonction est **unique**, ses **minimiseurs peuvent ne pas l'être** (il suffit de considérer n'importe quelle fonction **constante**). En particulier, tous les minimiseurs de J prennent la même valeur par J , qui vaut le minimum de J :

$$\forall x^* \in \operatorname{argmin}_{x \in \mathcal{X}} J(x), \quad J(x^*) = \min_{x \in \mathcal{X}} J(x)$$

En revanche, une fonction peut admettre plusieurs minima locaux.




FIGURE 1 – Minimiseur global *versus* minimiseur local. En **bleu** un minimiseur local, en **rouge** le minimiseur global.

Signalons, même s'ils seront relativement peu utilisés dans ce cours, la définition des maximiseurs et du maximum d'une fonction :

Définition 3 (Maximiseurs et maximum) — 最大值点和最大值

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{-\infty\}$ une fonction et $x^* \in \mathcal{X}$ tel que $J(x^*) \in \mathbb{R}$. On dit que x^* est un **maximiseur (global)** de J si

$$\forall x \in \mathcal{X}, \quad J(x^*) \geq J(x)$$

L'ensemble des **maximiseurs (globaux)** de J (éventuellement vide) est noté

$$\operatorname{argmax}_{x \in \mathcal{X}} J(x) \subset \mathcal{X}$$

Dans ce cas, la **valeur réelle** $J(x^*)$ est appelée **maximum (global)** de J , notée

$$\max_{x \in \mathcal{X}} J(x) \in \mathbb{R}$$

En réalité, il est aisé de vérifier que x^* est un **maximiseur de J si et seulement si x^* est un minimiseur de $-J$** . C'est pourquoi on peut confondre la notion d'optimisation et celle de minimisation, comme on le fera à partir de maintenant.

Il est clair qu'un **minimiseur global** est un **minimiseur local**. En général, la **réciprocité** est **fausse**, sauf dans le **cas convexe** :

Proposition 1 — 下凸函数的局部最小值点就是整体最小值点

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction **convexe**. Si $x^* \in \mathcal{X}$ est un **minimiseur local** de J , alors x^* est un **minimiseur global** de J .

DÉMONSTRATION : Admis. La preuve se trouve dans le module **B1 : Minimisation d'une fonction. Conditions d'optimalité.** (3MA261).

On peut à présent formaliser davantage le cadre des problèmes d'optimisation. On appelle *problème d'optimisation* la recherche d'un minimiseur ou d'un maximiseur d'une fonction objectif $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty, -\infty\}$, c'est-à-dire, dans le cas d'un **problème de minimisation**, la recherche d'un **point $x^* \in \mathcal{X}$** tel que $J(x^*) \in \mathbb{R}$ et

$$\forall x \in \mathcal{X}, \quad J(x^*) \leq J(x)$$

On le note de manière **équivalente**

$$\text{Minimiser } J \quad \text{ou} \quad \min_{x \in \mathcal{X}} J(x) \quad (\mathcal{P})$$

On parle de **problème d'optimisation sans contraintes**, car on ne contraint pas explicitement x à appartenir à un ensemble particulier. *A contrario*, un **problème d'optimisation sous contraintes** la recherche d'un **point $x^* \in \mathcal{C}$** tel que $J(x^*) \in \mathbb{R}$ et que

$$\forall x \in \mathcal{C}, \quad J(x^*) \leq J(x)$$

où l'ensemble $\mathcal{C} \subset \mathcal{X}$ est appelé **ensemble des contraintes** ou **ensemble admissible** (dans ce cas, tout point $x \in \mathcal{C}$ est appelé *point admissible*). Ce problème est alors noté

$$\text{Minimiser } J(x) \text{ sous les contraintes } x \in \mathcal{C} \quad \text{ou} \quad \min_{x \in \mathcal{C}} J(x) \quad (\mathcal{P}_c)$$

En utilisant une **fonction indicatrice**, 指示函数 il est toujours possible d'écrire un problème d'optimisation **sous contraintes** comme un problème d'optimisation **non contraint**, en définissant une nouvelle fonction objectif $\tilde{J} : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty, -\infty\}$ en posant

$$\forall x \in \mathcal{X}, \quad \tilde{J}(x) = J(x) + \chi_{\mathcal{C}}(x)$$

C'est la raison pour laquelle, sauf dans le cas particulier de la **dualité de LAGRANGE** (module **A6 : Dualité min-max**), on ne considérera dans ce cours que des problèmes d'optimisation **non contrainte**. 在课程中只考虑

Terminons ce paragraphe avec la notion de **problèmes équivalents**. Cette notion est formalisée ici d'une manière non standard :

Définition 4 (Problèmes d'optimisation équivalents) **等价优化问题**

Soit $J_1 : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ et $J_2 : \mathcal{Z} \rightarrow \mathbb{R} \cup \{+\infty\}$ deux fonctions. On note (\mathcal{P}_1) (resp. (\mathcal{P}_2)) le problème d'optimisation de fonction objectif J_1 (resp. J_2). On dit que les problèmes (\mathcal{P}_1) et (\mathcal{P}_2) sont **équivalents** s'il existe deux applications $M_1 : \mathcal{X} \rightarrow 2^{\mathcal{Z}}$ et $M_2 : \mathcal{Z} \rightarrow 2^{\mathcal{X}}$ telles que

$$x^* \in \operatorname{argmin}_{x \in \mathcal{X}} J_1(x) \quad \implies \quad M_1(x^*) \in \operatorname{argmin}_{z \in \mathcal{Z}} J_2(z)$$

$$\text{et} \quad z^* \in \operatorname{argmin}_{z \in \mathcal{Z}} J_2(z) \quad \implies \quad M_2(z^*) \in \operatorname{argmin}_{x \in \mathcal{X}} J_1(x)$$

Un cas particulier de problèmes équivalents est celui où les **fonctions objectifs** partagent **mêmes minimiseurs**. Ainsi, cette définition permet de généraliser cette notion ; il faut noter notamment que **deux problèmes équivalents** selon cette définition n'ont **pas nécessairement le même nombre de solutions**. Même lorsqu'elle n'est pas mentionnée de manière formelle, la notion de problèmes équivalents est très utile pour la résolution

de problèmes d'optimisation. Il est parfois possible d'introduire un problème auxiliaire dont les solutions permettent d'obtenir les solutions du problème initialement considéré. Remarquons enfin qu'aucune condition n'est imposée sur le minimum atteint dans les problèmes considérés.

等价优化问题

EXEMPLE

Problèmes d'optimisation équivalents. Considérons les deux fonctions objectives suivantes :

$$J_1 : \begin{cases} \mathbb{R} & \rightarrow \mathbb{R} \cup \{+\infty\} \\ x & \mapsto -x^2 + \chi_{[0;1]}(x) \end{cases} \quad \text{et} \quad J_2 : \begin{cases} \mathbb{R} & \rightarrow \mathbb{R} \cup \{+\infty\} \\ z & \mapsto -z^2 + \chi_{[-1;1]}(z) \end{cases}$$

Alors l'optimisation de ces deux fonctions définit deux problèmes équivalents, avec

$$M_1(x) = \{x, -x\} \quad \text{et} \quad M_2(z) = \{|z|\}$$

On remarque en particulier que la première fonction admet un unique minimiseur, tandis que le second en admet deux.

1.2 Existence et unicité des minimiseurs 最小值点的存在性和唯一性

Commençons par noter qu'une condition nécessaire d'existence de minimiseurs est le fait que J ne prenne pas la valeur $-\infty$ et ne soit pas identiquement égale à $+\infty$. Si J est convexe, cela revient à imposer que J soit propre.

Une autre notion qui apparaît souvent en optimisation est la suivante :

Définition 5 (Suite minimisante) 最小化序列

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction. On appelle suite minimisante de J toute suite $(x_k)_{k \in \mathbb{N}}$ de \mathcal{X} vérifiant

$$\lim_{k \rightarrow +\infty} J(x_k) = \inf_{x \in \mathcal{X}} J(x)$$

Notons que, si $\text{dom } J \neq \emptyset$, alors de toute suite minimisante, on peut extraire une sous-suite d'éléments appartenant au domaine de J . Dans le cas contraire, les $J(x_k)$ valent $+\infty$ à partir d'un certain rang, ce qui contredit le fait que la suite $(J(x_k))_{k \in \mathbb{N}}$ tend vers la borne inférieure de J (qui appartient à $\mathbb{R} \cup \{-\infty\}$ si le domaine de J est non vide). Par conséquent, on considère dorénavant que les suites minimisantes vivent dans le domaine de J .

Proposition 2 $\text{dom } J$ 不为空集, 则最小化序列存在

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction. On suppose que $\text{dom } J \neq \emptyset$. Alors J admet une suite minimisante.

DÉMONSTRATION : La preuve repose sur la caractérisation de la borne inférieure d'un sous-ensemble de \mathbb{R} . Notons

$$m = \inf_{x \in \mathcal{X}} J(x) \in \mathbb{R} \cup \{-\infty\}$$

- Cas $m = -\infty$. Pour tout $k \in \mathbb{N}$, il existe $x_k \in \text{dom } J$ tel que $J(x_k) \leq -k$. Par comparaison,

$$\lim_{k \rightarrow +\infty} J(x_k) = -\infty$$

- **Cas $m \in \mathbb{R}$.** Posons $\varepsilon_k = 1/(k+1)$ pour tout $k \in \mathbb{N}$. Alors il existe $x_k \in \text{dom } J$ tel que

$$m \leq J(x_k) < m + \varepsilon_k$$

de sorte que, par encadrement, on a

$$\lim_{k \rightarrow +\infty} J(x_k) = m \quad \blacksquare$$

Lorsque l'on étudie un problème d'optimisation, une question importante est celle de l'existence d'un minimiseur. Les résultats suivants permettent d'établir l'existence de minimiseurs sous certaines hypothèses. Si la fonction objectif considérée n'entre pas dans le champ d'application de ces résultats, elle peut ne pas admettre de minimiseur. Dans ce cas, pour le démontrer, une manière de procéder est d'exhiber une suite minimisante telle que la suite des images par la fonction objectif tend vers $-\infty$.

Mentionnons ci-dessous quelques résultats d'existence de minimiseurs. Il ne s'agit bien évidemment pas d'une liste exhaustive, mais de résultats classiques et généralement suffisants dans les applications. Le résultat suivant est une généralisation du théorème bien connu de WEIERSTRASS :

Proposition 3 (Existence de minimiseurs I) 定义域为非空紧集, 函数连续, 则存在最小值点

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction. On suppose que son domaine est compact non vide et que J est continue sur son domaine. Alors J admet un minimiseur.

DÉMONSTRATION : Admis.

La proposition 3 est utile lorsque le domaine de la fonction objectif est borné et qu'elle est continue sur son domaine. Cependant, un grand nombre de problèmes d'optimisation ne vérifie pas cette hypothèse. Dans ce cas, c'est en général la propriété dite de coercivité qui sera utilisée. Avant de l'introduire, on établit le résultat général suivant :

Proposition 4 下界点集有界, 则存在最小值点

On suppose que \mathcal{X} est de dimension finie. Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction continue sur son domaine. Supposons qu'il existe $x^0 \in \mathcal{X}$ tel que l'ensemble de niveau inférieur

$$\text{niv}_{\leq J(x^0)} J = \{x \in \mathcal{X} \mid J(x) \leq J(x^0)\}$$

soit borné. Alors J admet un minimiseur.

DÉMONSTRATION : Considérons la fonction suivante :

$$\tilde{J} = J + \chi_{\text{niv}_{\leq J(x^0)} J}$$

qui est une restriction de J sur l'ensemble $\text{niv}_{\leq J(x^0)} J$ (qui est inclus dans $\text{dom } J$). La continuité de J sur $\text{dom } J$ implique la continuité de \tilde{J} sur son domaine. Or, par hypothèse et construction, l'ensemble $\text{niv}_{\leq J(x^0)} J$ est un ensemble fermé et borné en dimension finie donc un ensemble compact. D'après la proposition 3, la fonction \tilde{J} admet donc un minimiseur, ce qui signifie qu'il existe $x^* \in \mathcal{X}$ tel que

$$\forall x \in \text{niv}_{\leq J(x^0)} J, \quad J(x) \geq J(x^*)$$

En particulier, puisque x^0 appartient à $\text{niv}_{\leq J(x^0)} J$, on a

$$J(x^0) \geq J(x^*)$$

Or, par définition de l'ensemble $\text{niv}_{\leq J(x^0)} J$, on a

$$\forall x \notin \text{niv}_{\leq J(x^0)} J, \quad J(x) > J(x^0) > J(x^*)$$

ce qui prouve que x^* est un minimiseur global de J . ■

Parmi les fonctions qui satisfont les hypothèses de la proposition précédente, il y a les fonctions *coercives* et continues sur leur domaine.

Définition 6 (Fonction coercive) — 强制函数

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty, -\infty\}$ une fonction. On dit que J est *coercive*, ou encore *infinie à l'infini*, si pour toute suite $(x_k)_{k \in \mathbb{N}} \in \mathcal{X}^{\mathbb{N}}$,
无穷到无穷

$$\lim_{k \rightarrow +\infty} \|x_k\| = +\infty \quad \implies \quad \lim_{k \rightarrow +\infty} J(x_k) = +\infty$$

Dans certains domaines des mathématiques, les termes *coercif* et *coercivité* désignent une tout autre propriété (connue aussi sous le nom d'*ellipticité*). Aussi, pour éviter toute ambiguïté, on parle parfois de *fonctions infinies à l'infini* (comme dans le polycopié du cours 3MA261 : Calcul différentiel et optimisation par exemple).

EXERCICE

Montrer que toute fonction $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ de domaine **borné** est **coercive**.

EXEMPLE

Fonctions coercives. D'après la définition, la **norme euclidienne** est une **fonction coercive**. De plus, si $f : \mathbb{R} \rightarrow \mathbb{R} \cup \{+\infty\}$ est une fonction telle que

$$\lim_{t \rightarrow +\infty} f(t) = +\infty$$

alors $x \mapsto f(\|x\|)$ est une **fonction coercive**. De manière générale, **si** J est **coercive**, **alors** $f \circ J$ l'est également.

Proposition 5 (Existence de minimiseurs II) — $\text{dom } J$ 非空闭集, J coercive 且连续, 则存在最小值点

On suppose que \mathcal{X} est de dimension finie. Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction telle que $\text{dom } J$ soit **fermé et non vide**. On suppose que J **coercive** et **continue sur son domaine**. Alors J admet un minimiseur.

DÉMONSTRATION : Il suffit de montrer que, dans ce cas, la fonction J est telle qu'il existe $x^0 \in \mathcal{X}$ tel que l'ensemble de niveau inférieur

$$\text{niv}_{\leq J(x^0)} J = \{x \in \mathcal{X} \mid J(x) \leq J(x^0)\}$$

soit **compact**, c'est-à-dire **fermé et borné**.

- $\text{niv}_{\leq J(x^0)} J$ est **fermé**. On commence par noter que $\text{niv}_{\leq J(x^0)} J \subset \text{dom } J$. Soit $(x_k)_{k \in \mathbb{N}}$ une suite de $\text{niv}_{\leq J(x^0)} J$. On suppose qu'elle converge vers x . Le domaine de J étant **fermé**, on en déduit que $J(x) \in \text{dom } J$. Ainsi, on a par définition de la suite des x_k et par **continuité** de J sur son domaine

$$\forall k \in \mathbb{N}, \quad J(x_k) \leq J(x_0) \quad \text{et} \quad \lim_{k \rightarrow +\infty} J(x_k) = J(x)$$

Il suffit de passer à la limite dans l'inégalité pour obtenir que $J(x) \leq J(x^0)$.

- **$\text{niv}_{\leq J(x^0)} J$ est borné.** On l'établit par l'absurde, en supposant que pour tout $x^0 \in \mathcal{X}$, l'ensemble $\text{niv}_{\leq J(x^0)} J$ n'est pas borné. Soit $x^0 \in \mathcal{X}$. Par hypothèse, il existe donc une suite $(x_k)_{k \in \mathbb{N}}$ de \mathcal{X} telle que

$$\lim_{k \rightarrow +\infty} \|x_k\|_2 = +\infty \quad \text{et} \quad \forall k \in \mathbb{N}, \quad J(x_k) \leq J(x_0)$$

La suite $(J(x_k))_{k \in \mathbb{N}}$ est donc bornée, en particulier, elle ne peut pas diverger vers $+\infty$, ce qui contredit le fait que J soit coercive.

Ainsi, la fonction J est continue sur le compact $\text{niv}_{\leq J(x^0)} J$, donc elle y admet un minimiseur, noté x^* . Par définition de x^* , on a

$$\forall x \notin \text{niv}_{\leq J(x^0)} J, \quad J(x) > J(x^0) \geq J(x^*)$$

Aussi, x^* est un minimiseur de J sur \mathcal{X} . ■

Attention, dans les propositions 3 et 5, l'hypothèse de continuité est importante :

紧集上的非连续函数

CONTRE-EXEMPLE

Fonction **discontinue** sur un compact. Considérons la fonction définie par :

$$\forall x \in \mathbb{R}, \quad J(x) = \begin{cases} 1 & \text{si } x = 0 \\ x^2 & \text{si } x \in [-1; 0[\cup]0; 1] \\ +\infty & \text{sinon} \end{cases}$$

Il est clair que cette fonction n'est pas continue en 0, mais que son domaine est compact. Alors on peut vérifier que

$$\forall x \in \mathbb{R}, \quad J(x) > 0 \quad \text{et} \quad \inf_{x \in \mathbb{R}} J(x) = 0$$

Autrement dit, J n'admet pas de minimiseur. Pourtant, cette fonction est coercive.

De la même manière, le caractère compact (c'est-à-dire borné et fermé en dimension finie) du domaine est essentiel :

非闭定义域

CONTRE-EXEMPLE

Domaine **non fermé**. Considérons la fonction définie par :

$$\forall x \in \mathbb{R}, \quad J(x) = \begin{cases} x & \text{si } x \in]-1; 1[\\ +\infty & \text{sinon} \end{cases}$$

Alors on peut vérifier que

$$\forall x \in \mathbb{R}, \quad J(x) > -1 \quad \text{et} \quad \inf_{x \in \mathbb{R}} J(x) = -1$$

Autrement dit, J n'admet pas de minimiseur. Pourtant, cette fonction est coercive, convexe et continue sur son domaine.

非有界定义域

CONTRE-EXEMPLE

Domaine **non borné**. Considérons la fonction définie par :

$$\forall x \in \mathbb{R}, \quad J(x) = \exp(x)$$

Alors on peut vérifier que

$$\forall x \in \mathbb{R}, \quad J(x) > 0 \quad \text{et} \quad \inf_{x \in \mathbb{R}} J(x) = 0$$

Autrement dit, J n'admet pas de minimiseur. Pourtant, cette fonction est convexe et continue sur son domaine, qui est fermé.

En réalité, il est possible de remplacer dans la proposition 5 l'hypothèse de continuité sur le domaine fermé non vide par celle de semi-continuité inférieure (module A1 : Éléments de topologie) :

Proposition 6 (Existence de minimiseurs III) — J coercive 且 s.c.i., 定义域非空, 则存在最小值点

On suppose que \mathcal{X} est de dimension finie. Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction coercive et s.c.i. On suppose que son domaine est non vide. Alors J admet un minimiseur.

DÉMONSTRATION : Soit $(x_k)_{k \in \mathbb{N}} \in (\text{dom } J)^{\mathbb{N}}$ une suite minimisante de J (qui existe d'après la proposition 2). Si cette suite n'est pas bornée, alors la suite des $\|x_k\|$ diverge vers $+\infty$. La coercivité de J assurerait donc que $(J(x_k))_{k \in \mathbb{N}}$ diverge vers $+\infty$, ce qui contredit le fait que cette suite a pour limite la borne inférieure de J (qui appartient à $\mathbb{R} \cup \{-\infty\}$ car $\text{dom } J \neq \emptyset$). Par conséquent, la suite $(x_k)_{k \in \mathbb{N}}$ est bornée. Elle admet donc une sous-suite $(x_{k_j})_{j \in \mathbb{N}}$ convergente. Notons x^* sa limite. Puisque J est s.c.i., il s'ensuit que

$$\inf_{x \in \mathcal{X}} J(x) \leq J(x^*) \leq \liminf_{j \rightarrow +\infty} J(x_{k_j}) = \lim_{j \rightarrow +\infty} J(x_{k_j}) = \inf_{x \in \mathcal{X}} J(x)$$

Autrement dit, x^* est un minimiseur de J . ■

En dimension infinie, de toute suite bornée on ne peut extraire que des sous-suites faiblement convergentes. Cependant, il est possible de montrer que, dans ce cas, ajouter l'hypothèse de convexité sur J permet d'assurer l'existence d'un minimiseur.

Terminons ce paragraphe avec deux résultats spécifiques aux fonctions convexes.

Proposition 7 (Unicité du minimiseur) — 严格凹函数 至多存在一个最小值点

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction strictement convexe. Alors J admet au plus un minimiseur.

DÉMONSTRATION : Supposons que J admet deux minimiseurs $x_1 \neq x_2$. Ces deux points appartiennent nécessairement au domaine de J . La fonction J étant strictement convexe, on a alors

$$J\left(\frac{x_1 + x_2}{2}\right) < \frac{J(x_1) + J(x_2)}{2} = J(x_1)$$

où le point $(x_1 + x_2)/2$ appartient au domaine, convexe, de J . Ceci est absurde car x_1 est un minimiseur de J . ■

Proposition 8 (Minimiseur d'une fonction fortement convexe) — 强凹函数 存在唯一 最小值点

On suppose que \mathcal{X} est de dimension finie. Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction s.c.i. On suppose que J est **fortement convexe**, de module α , et propre. Alors J admet un unique minimiseur.

存在唯一最小值点

DÉMONSTRATION : L'unicité du minimiseur est une conséquence directe de la stricte convexité de J . Il suffit alors de montrer que la fonction J est coercive. Puisqu'on est en dimension finie, J est sous-différentiable en tout point de l'intérieur relatif (non vide) de son domaine. Soit $x^0 \in \text{dom } f$ tel que $\partial J(x^0)$ soit non vide. Soit $p \in \partial J(x^0)$. Alors on a

$$\forall x \in \mathcal{X}, \quad J(x) \geq J(x^0) + \langle p, x - x^0 \rangle + \frac{\alpha}{2} \|x - x^0\|_2^2$$

En développant le carré, on montre qu'il existe $a \in \mathbb{R}^n$ et $b \in \mathbb{R}$ tel que

$$\forall x \in \mathbb{R}^n, \quad J(x) \geq \langle a, x \rangle + b + \frac{\alpha}{2} \|x\|_2^2$$

Il suffit alors d'expliciter l'écriture du produit scalaire et de la norme au carré, et de montrer (par l'absurde) que si $\|x_k\|_2$ tend vers $+\infty$, alors au moins une des coordonnées de la suite des x_k tend vers $+\infty$ aussi. ■

En dimension infinie, l'existence d'une minorante affine pour une fonction convexe s.c.i. et propre découle du théorème de FENCHEL-MOREAU (module A8 : Dualité de FENCHEL et conjuguée convexe), de sorte que toute fonction fortement convexe s.c.i. propre est coercive. La remarque de la page 8 assure donc l'existence d'un minimiseur pour toute fonction fortement convexe.

2 Condition d'optimalité du premier ordre — 一阶优化条件**2.1 Points critiques** — 驻点**Définition 7** (Point critique ou stationnaire) — 驻点

Soit $J : \mathcal{X} \rightarrow \overline{\mathbb{R}}$ une fonction. On appelle *point critique* ou *point stationnaire* de J tout point $x^* \in \mathcal{X}$ tel que

$$0 \in \partial J(x^*)$$

On note $\text{crit} J$ l'ensemble des points critiques de J .

Dans le cas différentiable, les points critiques sont exactement les zéros du gradient. Dans le cas d'une fonction réelle continûment dérivable, il existe quatre types de points critiques isolés :

- **minima locaux** : la dérivée y change de signe, passant du négatif au positif ;
- **maxima locaux** : la dérivée y change de signe, passant du positif au négatif ;
- **points d'inflexion montants** : la dérivée reste positive au voisinage du point ;
- **points d'inflexion descendants** : la dérivée reste négative au voisinage du point.

Il existe évidemment des exemples de points critiques non isolés, pour lesquels la dérivée reste nulle sur un voisinage.

2.2 Règle de FERMAT *Fermat 定理*

Proposition 9 (Condition nécessaire et suffisante d'optimalité du premier ordre) — **一阶优化 充分必要条件**

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction **convexe**. Soit $x^* \in \text{dom } J$. Alors on a l'**équivalence** entre les deux énoncés suivants :

- (i) x^* est un **minimiseur** de J ;
- (ii) $0 \in \partial J(x^*)$.

Cette condition est également connue sous le nom de *règle / théorème de FERMAT*; on parle parfois d'*équation d'EULER-LAGRANGE*.

DÉMONSTRATION : Par définition, si x^* est un **minimiseur de J si et seulement si**

$$\forall x \in \mathcal{X}, \quad J(x) \geq J(x^*) = J(x^*) + \langle 0, x - x^* \rangle$$

c'est-à-dire si et seulement si $0 \in \partial J(x^*)$. ■

Si J n'est **pas convexe**, alors cette condition **n'est plus suffisante** : 如果 J 不是 *convexe* 函数, 则该条件不充分

Proposition 10 (Condition nécessaire d'optimalité du premier ordre) — **一阶优化 必要条件**

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une **fonction**. Soit $x^* \in \text{dom } J$ un **minimiseur de J** . Alors $0 \in \partial J(x^*)$.

Autrement dit, **tout minimiseur est un point critique**. La réciproque est **en générale fausse**, puisqu'il **existe des points critiques qui ne sont pas des minimiseurs**. Dans le cas différentiable, on peut citer par exemple les minimiseurs locaux ou les maximiseurs (locaux et globaux).

DÉMONSTRATION : En reprenant les calculs de la preuve précédente, on prouve que si x^* est un **minimiseur de J** , alors $0 \in \hat{\partial} J(x^*) \subset \partial J(x^*)$. ■

3 Algorithmes du premier ordre *一阶算法*

3.1 Algorithmes d'optimisation *优化算法*

On formalise ici la notion d'algorithme utilisée dans ce cours.

Définition 8 (Algorithme) — **算法**

On définit un **algorithme** comme une application \mathcal{A} qui pour tout $k \in \mathbb{N}$, associe au point courant x_k et un **ensemble de paramètres \mathcal{P}_k** (appartenant à un espace vectoriel de dimension finie) un nouveau point x_{k+1} . La suite $(x_k)_{k \in \mathbb{N}} \subset \mathcal{X}^{\mathbb{N}}$ définie de manière récursive par

$$\forall k \in \mathbb{N}, \quad x_{k+1} = \mathcal{A}(x_k; \mathcal{P})$$

est alors dite générée par \mathcal{A} . Le **point initial x_0 est un des éléments de \mathcal{P}** .

REMARQUE : Dans cette définition, on suppose que la suite générée par \mathcal{A} est infinie. En pratique, cette suite sera toujours finie (ou, plus exactement, tronquée).

Un **algorithme d'optimisation** \mathcal{A} vise à résoudre le problème (\mathcal{P}) en générant une suite $(x_k)_{k \in \mathbb{N}} \in \mathcal{X}^{\mathbb{N}}$ qui doit, idéalement, **converger** vers un **point** x^* **minimiseur** de J :

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad \text{avec} \quad x^* \in \underset{x \in \mathcal{X}}{\operatorname{argmin}} J(x)$$

Un **algorithme d'optimisation** \mathcal{A} **du premier ordre** quant à lui tente de **trouver** un **minimiseur** de J en **recherchant** un **point critique** de J . Il doit donc être conçu de sorte de générer une suite $(x_k)_{k \in \mathbb{N}} \in \mathcal{X}^{\mathbb{N}}$ telle que

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad \text{avec} \quad 0 \in \partial J(x^*)$$

De manière générale, il faut donc s'assurer par ailleurs que le point critique trouvé est bien un minimiseur de J .

3.2 Modes de convergence 收敛模式

Démontrer la **convergence** d'un algorithme, c'est démontrer que la **suite générée** par celui-ci **converge bien** vers un **point satisfaisant** les **conditions désirées**. Dans le cadre des méthodes d'optimisation du premier ordre, ces conditions peuvent être écrites sous les **trois formes** suivantes

$$\bullet \text{ (minimiseur)} \quad x^* \in \underset{x \in \mathcal{X}}{\operatorname{argmin}} J(x) \quad (\text{C1})$$

$$\bullet \text{ (minimum)} \quad J(x^*) = \min_{x \in \mathcal{X}} J(x) \quad (\text{C2})$$

$$\bullet \text{ (point critique)} \quad 0 \in \partial J(x^*) \quad (\text{C3})$$

La propriété la plus forte est la première, dans le sens où **si** x^* est un **minimiseur** de J , **alors** $J(x^*)$ est le **minimum** de J et x^* est un **point critique** de J . La **seconde** condition est **moins exploitable**, car elle ne concerne que la valeur du minimum ; or celle-ci n'est pas suffisante pour déterminer un minimum. Enfin, la **dernière condition** est la **plus faible**, car un **point critique** n'est pas nécessairement un **minimiseur**. Notons que, même si la condition (C3) semble **équivalente** à la condition (C1) dans le cas d'une fonction **convexe**, elles sont en réalité très différentes : savoir qu'un point x^* admet pour (sous-)gradient 0 ne permet pas de le déterminer.

Les **preuves** de **convergence d'algorithmes** du premier ordre s'attachent donc à démontrer tout ou partie des propriétés suivantes sur les **suites** $(x_k)_{k \in \mathbb{N}}$ générées par un **algorithme** \mathcal{A} . Commençons par les propriétés de **convergence forte**, c'est-à-dire portant sur la suite $(x_k)_{k \in \mathbb{N}}$:

- convergence de la suite des itérés x_k :

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad (\text{A-I})$$

- convergence des itérés vers un **minimiseur** de J :

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad \text{avec} \quad x^* \in \underset{x \in \mathcal{X}}{\operatorname{argmin}} J(x) \quad (\text{A-II})$$

- convergence des itérés vers un **point critique** de J :

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad \text{avec} \quad 0 \in \partial J(x^*) \quad (\text{A-III})$$

Il s'agit en général des propriétés les plus difficiles à établir. Pour certains algorithmes, il est même **nécessaire** de se contenter de la **convergence d'une sous-suite** (ou de toutes les sous-suites). Le **deuxième ensemble** de propriétés concerne la **convergence de la suite** $(J(x_k))_{k \in \mathbb{N}}$: 函数值的收敛性

- convergence en valeur / du critère :

$$\lim_{k \rightarrow +\infty} J(x_k) = J^* \quad (\text{B-I})$$

- convergence en valeur / du critère vers le **minimum de J** (suite minimisante) :

$$\lim_{k \rightarrow +\infty} J(x_k) = \min_{x \in \mathcal{X}} J(x) \quad (\text{B-II})$$

La première propriété est souvent la plus facile à établir (et, pour une certaine classe d'algorithmes, dans une forme plus forte, à savoir la monotonie de la suite des $J(x_k)$). Enfin, considérons les **propriétés de convergence** du premier ordre à proprement parler, c'est-à-dire celles qui concernent la **suite $(p_k)_{k \in \mathbb{N}}$** (avec p_k un sous-gradient de J en x_k) :

- convergence des **sous-gradients** :

$$\forall k \in \mathbb{N}, \exists p_k \in \partial J(x_k), \quad \lim_{k \rightarrow +\infty} p_k = p^* \quad (\text{C-I})$$

- convergence vers le **critère d'optimalité** / des sous-gradients **vers 0** :

$$\forall k \in \mathbb{N}, \exists p_k \in \partial J(x_k), \quad \lim_{k \rightarrow +\infty} p_k = 0 \quad (\text{C-II})$$

Insistons sur le fait qu'en général, la **dernière propriété ne suffit pas** (même dans le cas convexe), à démontrer la **convergence forte** de l'algorithme **vers un minimiseur de J** . Notons par ailleurs qu'il n'est pas toujours possible de démontrer tous ces modes de convergence pour un même algorithme. Toutefois, **sous certaines hypothèses** sur le problème (sur la fonction objectif J), il **existe des liens** naturels entre certains modes de convergence. En voici quelques uns :

Proposition 11 (Cas continu) 连续情形

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction. Soit $(x_k)_{k \in \mathbb{N}}$ une suite générée par un algorithme \mathcal{A} . Soit $x^* \in \text{dom } J$. On suppose que l'une des deux hypothèses suivantes est vérifiée : 以下两个假设中的一个成立

- (i) le point $x^* \in \text{int}(\text{dom } J)$ et J est continue au voisinage de x^* ;
- (ii) la fonction J est continue sur son domaine et il existe $k_0 \in \mathbb{N}$ tel que

$$\forall k \geq k_0, \quad x_k \in \text{dom } J$$

$$\text{Alors} \quad \lim_{k \rightarrow +\infty} x_k = x^* \quad \implies \quad \lim_{k \rightarrow +\infty} J(x_k) = J(x^*)$$

De plus, si x^* est un minimiseur de J , alors $J(x^*)$ est le minimum de J .

Autrement dit, la **convergence** des itérées (A-I) (resp. vers un minimiseur (A-II)) **implique la convergence en valeur** (B-I) (resp. vers le minimum (B-II)).

Dans le cas convexe, on a le résultat suivant :

Proposition 12 (Cas convexe) 凸情形

Soit $J : \mathcal{X} \rightarrow \mathbb{R}$ une fonction **convexe propre**. On suppose que J admet un **minimiseur**. Soit $(x_k)_{k \in \mathbb{N}}$ une suite générée par un algorithme \mathcal{A} . On suppose que la suite $(x_k)_{k \in \mathbb{N}}$ est **bornée** et que

$$\forall k \in \mathbb{N}, \quad p_k \in \partial J(x_k) \quad \text{avec} \quad \lim_{k \rightarrow +\infty} p_k = 0$$

Alors la suite $(J(x_k))_{k \in \mathbb{N}}$ **converge** vers le **minimum de J** .

DÉMONSTRATION : Soit $k \in \mathbb{N}$ et x^* un minimiseur de J . D'après la **convexité** de J ,

$$J(x^*) \geq J(x_k) + \langle p_k, x^* - x_k \rangle$$

L'inégalité de CAUCHY-SCHWARZ permet d'obtenir la majoration suivante :

$$0 \leq J(x_k) - J(x^*) \leq \|p_k\| \|x_k - x^*\|$$

Par comparaison, on obtient le résultat désiré. ■

Ce dernier résultat nécessite de montrer que la suite générée par l'algorithme est bornée. Ce n'est pas toujours le cas, ni évident à établir. Notons par ailleurs que rien ne garantit la convergence forte de l'algorithme.

Grâce à la **fermeture du sous-différentiel**, on peut démontrer le résultat suivant :

次微分の閉性

Proposition 13

Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction. Soit $(x_k)_{k \in \mathbb{N}}$ une suite générée par un algorithme \mathcal{A} . Soit $x^* \in \text{dom } J$. On suppose que

$$\lim_{k \rightarrow +\infty} x_k = x^* \quad \text{et} \quad \lim_{k \rightarrow +\infty} J(x_k) = J(x^*)$$

et que $\forall k \in \mathbb{N}, \quad p_k \in \partial J(x_k) \quad \text{avec} \quad \lim_{k \rightarrow +\infty} p_k = 0$

Alors $0 \in \partial J(x^*)$

Autrement dit, la **convergence des itérées (A-I)**, du **critère d'optimalité (C-I)** et des **sous-gradients vers 0 (B-II)** implique la **convergence des itérés vers un point critique (A-III)**.

Dans le cas **fortement convexe** en dimension finie, on peut établir le résultat suivant :

強凹函数情形

Proposition 14

On suppose que \mathcal{X} est de **dimension finie**. Soit $J : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$ une fonction **fortement convexe**, de module α , s.c.i. et propre. Soit x^* l'unique minimiseur de J . Soit $(x_k)_{k \in \mathbb{N}}$ une suite générée par un algorithme \mathcal{A} . Alors

$$\forall k \in \mathbb{N}, \quad \|x_k - x^*\|_2^2 \leq \frac{2}{\alpha} \left(J(x_k) - \min_{\mathcal{X}} J \right)$$

DÉMONSTRATION : Soit $k \in \mathbb{N}$. On écrit la définition de la **forte convexité** de J aux points x_k et x^* :

$$\forall \lambda \in [0; 1], \quad J(\lambda x_k + (1 - \lambda) x^*) \leq \lambda J(x_k) + (1 - \lambda) J(x^*) - \frac{\alpha}{2} \lambda (1 - \lambda) \|x_k - x^*\|_2^2$$

Par définition de x^* , on a

$$\forall \lambda \in [0; 1], \quad J(x^*) \leq J(\lambda x_k + (1 - \lambda) x^*)$$

de sorte que l'inégalité précédente se simplifie en

$$\forall \lambda \in [0; 1], \quad \|x_k - x^*\|_2^2 \leq \frac{2}{\alpha(1 - \lambda)} (J(x_k) - J(x^*))$$

Il suffit alors de majorer la quantité $1 - \lambda$ pour obtenir le résultat désiré. ■

Ainsi, si J est fortement convexe s.c.i. en dimension finie, alors toute suite minimisante de J converge vers le minimiseur de J . Ce résultat n'est évident pas vrai en général (il suffit de considérer par exemple une fonction constante sur \mathbb{R} et la suite des entiers naturels). Autrement dit, la convergence du critère vers le minimum (B-II) entraîne la convergence forte vers le minimiseur (A-II).

Les différents modes de convergence permettent de définir des *critères d'arrêt* pour les algorithmes, c'est-à-dire de définir une condition qui, une fois satisfaite, entraîne l'arrêt des itérations. Un bon critère d'arrêt doit stopper les itérations en un temps fini raisonnable (quelques secondes, minutes, heures en général, suivant les applications), aboutir à une itération suffisamment proche du point recherché et ne doit pas être trop complexe à calculer.

Ainsi par exemple, si on a démontré que la convergence des sous-gradients vers 0 (C-II), un critère d'arrêt pourrait être défini à l'aide d'un seuil dit de *tolérance* $\varepsilon > 0$, qui permettrait d'arrêter les itérations dès que la condition suivante est satisfaite pour un certain $k \in \mathbb{N}$:

$$\|p_k\| < \varepsilon \quad \text{avec} \quad p_k \in \partial J(x_k)$$

Ce critère est exploitable à condition qu'un tel p_k soit calculable (et on a vu dans le module **A2 : Sous-différentiabilité** qu'il est parfois difficile à déterminer) et avec une complexité raisonnable. Évidemment, si ε est choisi trop grand, alors le point final obtenu x_k peut être trop éloigné d'un minimiseur (ou d'un point critique) de J . En revanche, si ε est trop petit, il faudra peut-être trop d'itérations pour satisfaire le critère d'arrêt défini. En pratique, le choix de la valeur ε est parfois difficile, d'autant que le lien entre la valeur $\|p_k\|$ et la distance de x_k au minimiseur / point critique x^* (le cas échéant) n'est pas toujours explicite.

Pour s'affranchir de cette difficulté, on serait tenté d'utiliser un autre mode de convergence. Le plus naturel est d'utiliser la convergence des itérés x_k vers un point x^* (A). En effet, définir comme critère d'arrêt

$$\|x_k - x^*\| < \varepsilon$$

permet de contrôler très précisément l'erreur commise. Malheureusement, un tel critère d'arrêt nécessite de connaître le point x^* , ce qui n'est évidemment pas le cas puisque c'est justement le point recherché. Un moyen simple d'utiliser la convergence des itérés (si elle est démontrée) est de définir plutôt un critère d'arrêt de la forme

$$\|x_{k+1} - x_k\| < \varepsilon$$

Malheureusement, il est alors difficile d'en déduire l'erreur commise à l'issue des itérations. Si ε est choisi très petit (par exemple $\varepsilon = 10^{-9}$), on peut numériquement estimer que le point limite x^* est atteint, car la suite des itérés reste constante à un arrondi près (même si rien n'interdit à la suite des itérées de "stagner" momentanément !). Les mêmes remarques sont valables si on utilise la convergence du critère (B).

3.3 Taux de convergence 收敛速率

Afin de pour définir des critères d'arrêt raisonnables, il est souvent utile d'avoir une idée de la *vitesse de convergence* d'un algorithme, c'est-à-dire de la vitesse de convergence de la distance des suites générées par l'algorithme à leur limite (s'il a été démontré qu'elle existait) vers 0. On prend l'exemple de la convergence des itérés.

Définition 9 (Taux de convergence) 收敛速率

Soit $(x_k)_{k \in \mathbb{N}}$ une suite générée par un algorithme \mathcal{A} . On suppose qu'elle converge vers $x^* \in \mathcal{X}$, et qu'elle ne converge pas en un nombre fini d'itérations. La convergence de l'algorithme \mathcal{A} est dite :

- *linéaire* s'il existe $\tau \in]0; 1[$ tel que

$$\lim_{k \rightarrow +\infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = \tau$$

- *d'ordre p* s'il existe $\tau \in [0; +\infty[$ tel que

$$\lim_{k \rightarrow +\infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^p} = \tau$$

REMARQUE : Si $p = 2$, on parle de taux de convergence *quadratique*.

二阶收敛速率

La convergence linéaire est la plus intéressante, mais généralement réservée à des problèmes très réguliers. Elle se traduit par une décroissance exponentielle de l'erreur (ici $\|x_k - x^*\|$). On peut parfois démontrer des taux de convergence linéaire (ou d'ordre p) pour les suites $(J(x_k))_{k \in \mathbb{N}}$ et $(p_k)_{k \in \mathbb{N}}$.

Afin de conserver une taille raisonnable pour ce polycopié, l'estimation des taux de convergence pour les algorithmes étudiés ne sera pas examinée.

Pour aller plus loin

Optimisation sous contraintes. L'introduction de la droite achevée permet de transformer les problèmes d'optimisation sous contraintes en problèmes non contraints. Plus précisément, elle permet d'utiliser un formalisme commun pour étudier les deux types de problèmes, en incorporant dans la fonction objectif les contraintes à l'aide de l'indicatrice de l'ensemble admissible. De fait, un problème sous contraintes (différentiable ou non) peut donc toujours être vu comme un problème d'optimisation **non différentiable** non contraint.

Problèmes équivalents. Pour certains algorithmes, il peut être plus simple d'introduire un problème auxiliaire équivalent et s'intéresser à la résolution de ce problème auxiliaire pour en déduire celle du problème initial.

Modes de convergence. Pour chacune des méthodes d'optimisation que l'on étudiera dans les modules suivants, on s'attachera à démontrer les différents modes de convergence présentés dans ce module.